

異方性拡散を活用した 管状構造セグメンテーションにおける 連続性の向上

2025/2/3



情報認識学研究室

佐野 裕馬


背景：画像セグメンテーション

1

画像中の物体領域を切り分けるタスクであり、多くの応用分野において重要な役割を果たす



医療画像解析



自動運転技術

背景：一般的なセグメンテーション


2

画像中の人物や自動車, 動物などの領域をマスク抽出するタスク

モデルの評価指標は, 各オブジェクトの面積一致から
精度を評価する**面積ベース**が主流である



人物や車などのセグメンテーション



$$\text{Dice} = \frac{2|V_P \cap V_L|}{|V_P| + |V_L|}$$

面積ベース指標 Dice

背景：管状構造セグメンテーション

3


細長い対象をマスク抽出するタスク

→マスクの正しい接続性が極めて重要となる

例) 血管領域の抽出が血流の解析に用いられる場合,
マスクの途切れによって誤った判断に繋がる



地面のひび割れ




血管

背景：管状構造セグメンテーション

4

- 面積ベース指標ではマスクの途切れを評価できない
- 一般的なセグメンテーションモデルを用いても
マスクが途切れ，連続性という点で良い結果が得られない



Image



Ground truth




U-Net

課題解決の仮説

5

管状方向に沿ってマスクを拡張できれば
適切にマスクの途切れ (断片化) を解消できるのではないか



関連研究：二重閾値反復法 (DTI) [1]

6

[1] Liu+, JBHI, 2022

閾値から僅かに低い予測値を持つピクセルに対して、
予測マスクに隣接していれば、マスクに含めるプロセスを反復する

マスクの連続性を向上できるが、
管状幅方向に対して過剰にマスクを拡張してしまう



U-Net




U-Net + DTI

関連研究：レベルセット法

7

画像特徴に合わせて設計された**偏微分方程式 (PDE)**を解き、セグメンテーション境界を物体表面に誘導する手法

深層学習モデルの台頭以前まで、よく用いられていた



レベルセット法による反復的なセグメンテーション結果

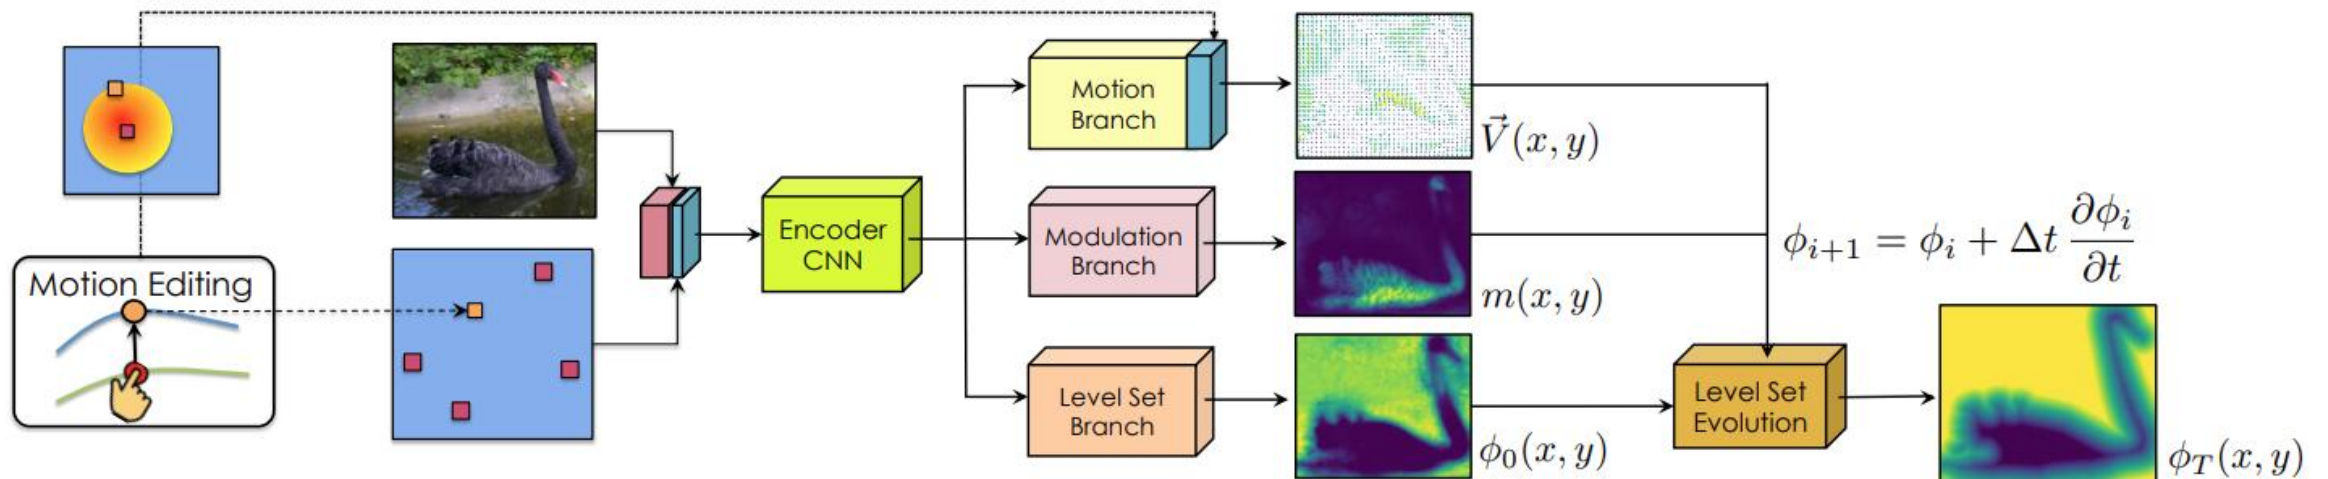
関連研究：深層学習と偏微分方程式の統合 [2]

8

[2] Wang+, CVPR, 2019

- 深層学習 : 画像から特徴を抽出する能力に長けている
- レベルセット法 : 設計されたPDEによるセグメンテーションの柔軟さ

深層学習によってレベルセット法のパラメータを出力し、
良く設計されたPDEを解くことで、セグメンテーションを洗練する



関連研究：深層学習と偏微分方程式の統合 [2]

9

[2] Wang+, CVPR, 2019

管状構造の連続性を向上させにくい問題がある

- 面積ベース指標 (**ピクセル単位の正確さ**) を向上させる目的で学習
- PDEにマスク境界を滑らかにする拡散項が存在する
 - 予測マスクは滑らかに (丸く) なるようとするため, 断片化しやすい

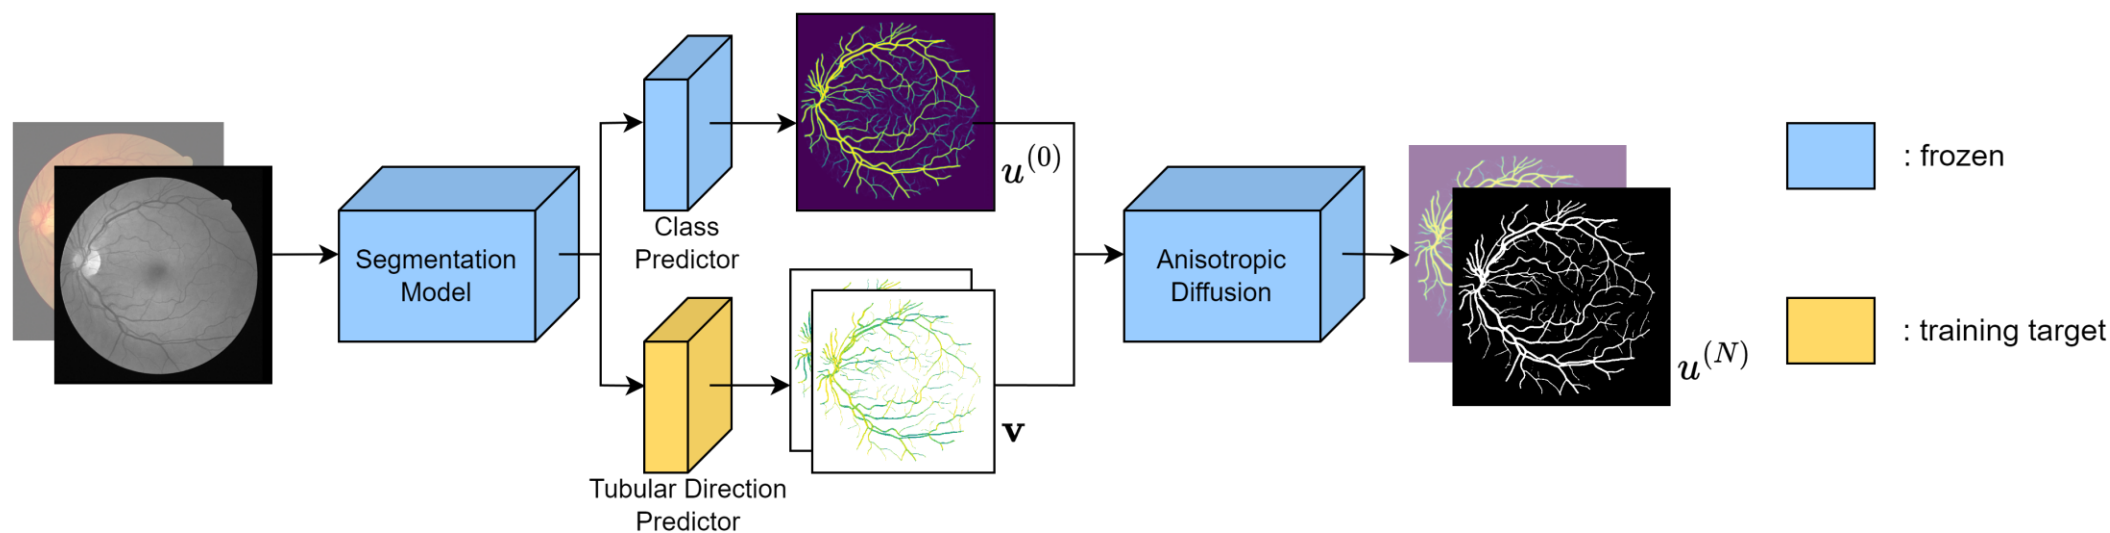
$$\frac{\partial \phi_i}{\partial t} = - \langle \vec{V}_\theta, \nabla \phi_i \rangle + \lambda \cdot m_\theta |\nabla \phi_i| \operatorname{div} \left(\frac{\nabla \phi_i}{|\nabla \phi_i|} \right) + \mu \cdot \operatorname{div} \left(p'(|\nabla \phi_i|) \frac{\nabla \phi_i}{|\nabla \phi_i|} \right)$$

拡散項

異方性拡散による管状構造に沿った予測マスクの連続性向上

管状構造に対する事前知識をPDEとして設計し、
既存モデルのクラス予測場に対する、最適化可能な後処理として組み込む

仮説で述べた、管状方向に沿ったマスク領域の拡張を実現




提案手法：異方性拡散

11


クラス予測場を拡散させる際，速度を方向情報に応じて変動させる

方向ベクトル \mathbf{v} ， \mathbf{v} の拡散係数 λ_{\parallel} ，垂直方向の拡散係数 λ_{\perp} を用いて，異方性拡散を実現するの必要となる**拡散テンソル \mathbf{D}** を構成する


$$\mathbf{D}(x, y) = \lambda_{\parallel}(x, y)\mathbf{v}(x, y)\mathbf{v}(x, y)^T + \lambda_{\perp}(x, y)(\mathbf{I} - \mathbf{v}(x, y)\mathbf{v}(x, y)^T)$$



等方性拡散後



拡散前の予測場



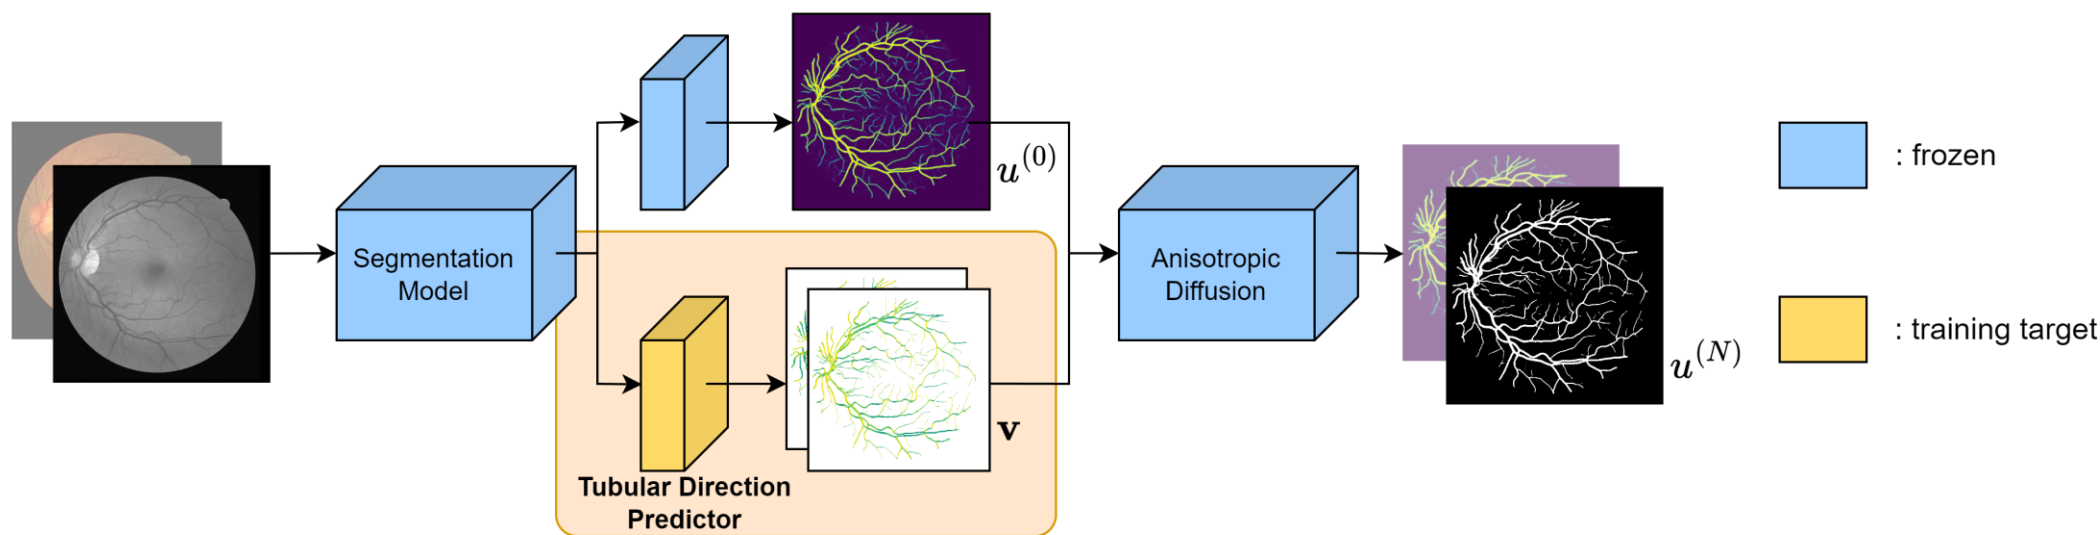
異方性拡散後

提案手法：方向推定層

12

既存モデルの特徴空間に管状方向を推定する方向推定層を追加する
方向推定層：単層の畳み込み層

推定方向 \mathbf{v} を異方性拡散の枠組みに用いることで、
推定した管状方向に沿ったクラス予測場の拡散を実現する



提案手法：連続性のための偏微分方程式

13

- 通常の拡散方程式

$$\frac{\partial u}{\partial t} = \left(\nabla \cdot (\mathbf{D} \nabla u) \right) \quad (1)$$

値が拡散して均一になる過程を記述

→高い予測値が拡散されることによって予測値の減少が発生する

- 提案する拡散方程式

$$\frac{\partial u}{\partial t} = f(\mathbf{D}, u) = \text{ReLU} \left(\left(\nabla \cdot (\mathbf{D} \nabla u) \right) \right) \quad (2)$$

高い予測値を維持したまま，その周囲の予測値を向上させる

→マスクの連続性を向上させるという目的に合致

提案手法：アルゴリズム

14

1. 既存モデルから，クラス予測場 u と特徴マップ F を出力する
2. 方向推定層に F を入力することで，
各ピクセルにおいて管状方向 \mathbf{v} を推定する
3. \mathbf{v} を用いて，異方性拡散に必要な拡散テンソル \mathbf{D} を計算する
4. 設計した偏微分方程式を，4次ルンゲクッタ法で反復的に解く

$$\frac{\partial u}{\partial t} = f(\mathbf{D}, u) = \text{ReLU}\left(\left(\nabla \cdot (\mathbf{D} \nabla u)\right)\right) \quad (2)$$

実験設定：データセット


15

網膜画像データセットDRIVE

- 訓練データ20枚, テストデータ20枚から構成される
- テストデータを用いてモデルを評価する



網膜画像



真のマスク(網膜血管)

実験設定：アーキテクチャ

16

[1] Liu+, JBHI, 2022

- U-NetとSoTAに近いモデルFR-UNet[1]を既存モデルとして採用し、既存モデルによる提案手法の有効性への影響を明らかにする
(提案手法の有効性を確認)
- 方向推定層 (単層畳み込み層)のカーネルサイズを変更し、予測マスクへの影響を明らかにする
(提案手法が有効であれば、もっとも良い設定を探索)

- Dice係数 (↑)

2つのマスクの面積一致の度合いを評価する

- cIDice (↑)

予測マスクのスケルトンが真のマスクにどれだけ含まれるか、
またはその逆を総合的に評価する

値が大きいほど、**マスクのネットワーク構造**が類似

- VCA (↓)

予測マスクと真のマスクに含まれる連結成分数の比

値が小さいほど、**マスクの連続性**が高い

実験結果：U-Netへの適用 (評価指標)

18

方向推定層のカーネルサイズを変更して，提案手法 (increase) を評価
kernel- i は $i \times i$ のカーネルサイズで方向推定層を実装したことを示す

モデル	Dice (↑)	clDice (↑)	VCA (↓)
U-Net	0.7454	0.7200	5.477×10
U-Net + increase (kernel-1)	0.7206	0.7206	6.857×10
U-Net + increase (kernel-3)	0.7576	0.7321	5.025×10
U-Net + increase (kernel-5)	0.7585	0.7363	4.934×10
U-Net + increase (kernel-7)	0.7585	0.7353	4.564×10
U-Net + increase (kernel-9)	0.7596	0.7413	4.347×10
U-Net + increase (kernel-11)	0.7591	0.7373	4.473×10
U-Net + increase (kernel-13)	0.7591	0.7368	4.569×10

実験結果：U-Netへの適用 (予測マスク)

19

- **U-Net**

マスクの断片化が発生する

- **提案手法 (kernel-1)**

断片化したマスクを連続化するが、
管状方向に沿った拡散ではない

- **提案手法 (kernel-9)**

管状構造に沿って
断片化したマスクを連続化する



Ground truth



U-Net



kernel-1



kernel-9

実験結果：U-Netへの適用 (推定方向)

20

推定方向 \mathbf{v} の X 方向成分の絶対値を血管上で可視化

ピクセルが黄色に近いほど X 方向に沿った方向を示す

紺色に近いほど Y 方向に沿った方向を示す

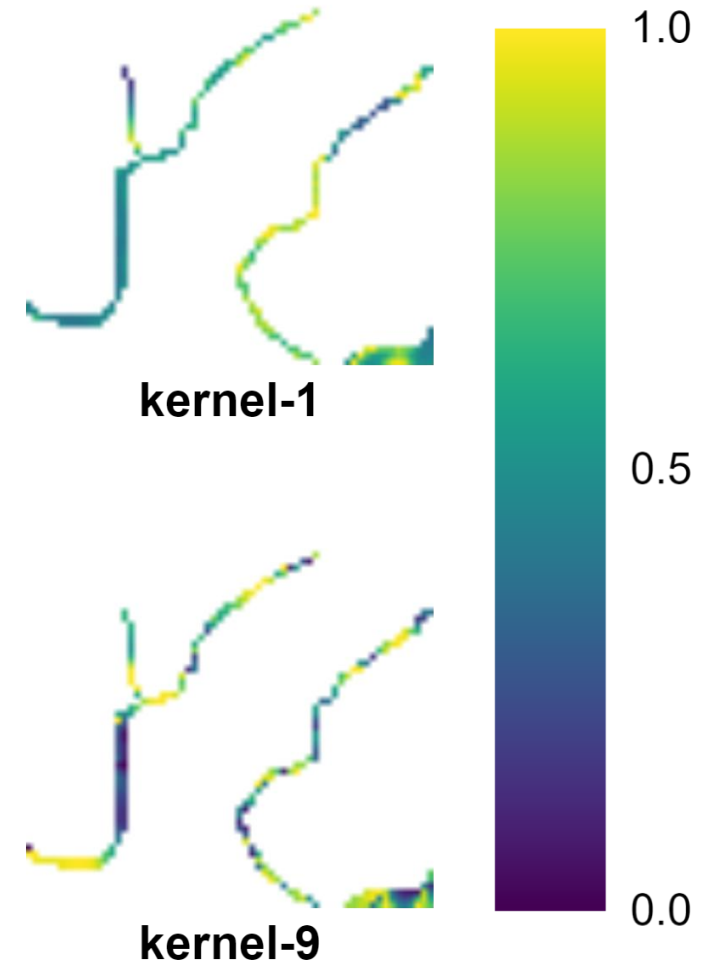
- **kernel-1**

誤った管状方向を推定している箇所が目立つ

- **kernel-9**

kernel-1に比べ，おおむね正しく管状方向を推定

管状方向に沿った拡散を実現



実験結果：FR-UNetへの適用 (予測マスク)

21

- **FR-UNet**

U-Netに比べて高精度な
予測マスクを出力する

- **二重閾値反復法 (DTI)**

マスクの連続化を実現するが、
管状幅方向にも拡張してしまう

- **提案手法 (increase)**

既存モデルに比べて断片部が減少し、
DTIと比べて幅方向への拡張も抑制する



Ground truth



FR-UNet



FR-UNet + DTI



FR-UNet + increase

実験結果：FR-UNetへの適用 (予測マスク)

22

- **FR-UNet**

U-Netに比べて高精度な
予測マスクを出力する

- **二重閾値反復法 (DTI)**

マスクの連続化を実現するが、
管状幅方向にも拡張してしまう

- **提案手法 (increase)**

既存モデルに比べて断片部が減少し、
DTIと比べて幅方向への拡張も抑制する



Ground truth



FR-UNet



FR-UNet + DTI



FR-UNet + increase

実験結果：FR-UNetへの適用 (評価指標)

23

- **二重閾値反復法 (DTI)**

連続性 (VCA)は大幅に改善するが、ネットワーク性 (clDice)が悪化した
→管状幅方向にもマスクを拡張し、**不必要な接続**が生まれた可能性がある

- **提案手法 (increase)**

- ネットワーク性 (clDice)と連続性 (VCA)の両方が改善した
- DTIに比べ、面積一致指標 (Dice)の減少も抑えられ、
管状構造に沿った適切なマスク接続が行えていると考える

モデル	Dice (↑)	clDice (↑)	VCA (↓)
FR-UNet	0.8316	0.8103	3.664×10
FR-UNet + DTI	0.8139	0.7999	5.783
FR-UNet + increase	0.8290	0.8113	3.311×10

- **課題** 管状構造セグメンテーションにおいて予測マスクが断片化する
- **仮説** 管状構造に沿ってマスクを伸ばせば、断片化を適切に解消できる
- **提案手法** 異方性拡散を用いて、既存モデルのクラス予測場を管状方向に沿うように拡散させる
- **結果** U-Netに適用した場合、評価指標が全て改善し、FR-UNetに適用した場合、ネットワーク性と連続性指標が改善した

従来の連続化処理 (DTI)と比較し、提案手法を用いることで、ネットワーク性を維持しつつ、予測マスクの連続性を向上できた

より良いPDEを設計する

他のデータセットにおいて有効性を確認する

提案手法は、既存モデルに対して簡単に統合可能である

管状構造セグメンテーションは、着実に研究が進められている

→ 新たなモデルが発表された際、提案手法を組み合わせることで
性能が改善されるのかを確認する

- [1] Wentao Liu, Huihua Yang, Tong Tian, Zhiwei Cao, Xipeng Pan, Weijin Xu, Yang Jin, and Feng Gao. Full-Resolution Network and Dual-Threshold Iteration for Retinal Vessel and Coronary Angiograph Segmentation. *IEEE Transactions on Medical Imaging*, 41(5):1234–1245, 2022.
- [2] Zian Wang, David Acuna, Huan Ling, Amlan Kar, and Sanja Fidler. Object Instance Annotation with Deep Extreme Level Set Evolution. In *IEEE / CVF Computer Vision and Pattern Recognition Conference – CVPR*, 2019.
- [3] Olaf Ronneberger, Philipp Fischer, and Thomas Brox. U-Net: Convolutional Networks for Biomedical Image Segmentation. In *International Conference on Medical Image Computing and Computer-Assisted Intervention – MICCAI*, 2015.
- [4] Pietro Perona and Jitendra Malik. Scale-space and edge detection using anisotropic diffusion. *IEEE Computer Society Workshop on Computer Vision*, pages 16–22, 1987.
- [5] Stanley Osher and James A Sethian. Fronts propagating with curvature-dependent speed: Algorithms based on Hamilton-Jacobi formulations. *Journal of Computational Physics*, 79(1):12–49, 1988.
- [6] Suprosanna Shit, Johannes C. Paetzold, Anjany Sekuboyina, Ivan Ezhov, Alexander Unger, Andrey Zhylyka, Josien P. W. Pluim, Ulrich Bauer, and Bjoern H. Menze. cDice – A Novel Topology-Preserving Loss Function for Tubular Structure Segmentation. In *IEEE / CVF Computer Vision and Pattern Recognition Conference – CVPR*, 2021.


- [7] Bengt Fornberg. Generation of Finite Difference Formulas on Arbitrarily Spaced Grids. *Mathematics of Computation*, 51(184):699–706, 1988.
- [8] Wei Liao. Segmentation of Tubular Structures Using Iterative Training with Tailored Samples. In *International Conference on Computer Vision – ICCV*, 2023
- [9] Jiaxing Huang, Yanfeng Zhou, Yaoru Luo, Guole Liu, Heng Guo, Ge Yang. Representing Topological Self-Similarity Using Fractal Feature Maps for Accurate Segmentation of Tubular Structures. In *European Conference on Computer Vision – ECCV*, 2024

- 物体境界を陰的に表現

符号付距離関数 ϕ を用いて，物体境界を $C = \{(x, y) | u(x, y) = 0\}$ として表現

物体領域は $\Omega = \{(x, y) | u(x, y) \leq 0\}$ として表せる

陰的に物体境界を表現できるため，
境界のトポロジーを柔軟に変更できる



付録：高精度な有限差分

29

[7] Fornberg , Mathematics of Computation, 1988

• 中心差分における各位置における重み付け

精度の高い $[-4, 4]$ の範囲の有限差分を採用して、
勾配計算 ∇u と発散計算 $\nabla \cdot (\mathbf{D}\nabla u)$ を行う

Order of derivative	Order of accuracy	Approximations at $x = 0$; x -coordinates at nodes:								
		-4	-3	-2	-1	0	1	2	3	4
0	∞	1								
1	2				$-\frac{1}{2}$	0	$\frac{1}{2}$			
	4			$\frac{1}{12}$	$-\frac{2}{3}$	0	$\frac{2}{3}$	$-\frac{1}{12}$		
	6		$-\frac{1}{60}$	$\frac{3}{20}$	$-\frac{3}{4}$	0	$\frac{3}{4}$	$-\frac{3}{20}$	$\frac{1}{60}$	
	8	$\frac{1}{280}$	$-\frac{4}{105}$	$\frac{1}{5}$	$-\frac{4}{5}$	0	$\frac{4}{5}$	$-\frac{1}{5}$	$\frac{4}{105}$	$-\frac{1}{280}$

付録：4次ルンゲクッタ法

30

$$k_1 \leftarrow f(\mathbf{D}, u^{(n)})$$

$$k_2 \leftarrow f\left(\mathbf{D}, u^{(n)} + \frac{\Delta t}{2} k_1\right)$$

$$k_3 \leftarrow f\left(\mathbf{D}, u^{(n)} + \frac{\Delta t}{2} k_2\right)$$

$$k_4 \leftarrow f\left(\mathbf{D}, u^{(n)} + \Delta t k_3\right)$$

$$u^{(n+1)} \leftarrow u^{(n)} + \frac{\Delta t}{6} (k_1 + 2k_2 + 2k_3 + k_4)$$

$$u^{(n+1)} \leftarrow \min\left(\max(u^{(n+1)}, 0), 1\right)$$

$$\triangleright f(\mathbf{D}, u) = \text{ReLU}\left(\nabla \cdot (\mathbf{D}(x, y) \nabla u)\right)$$

▷ 4 次ルンゲクッタ法

▷ 出力を $[0, 1]$ にクリッピング

- 画像サイズ

- 既存モデルの訓練：48 × 48
- 提案モデルの訓練：512 × 512

- データ拡張

0度, 90度, 180度, 270度の回転を等確率で適用
水平反転, 垂直反転を各1/2の確率で適用

- 訓練設定 (提案モデル)

バッチサイズを64, パラメータ更新回数は10 * 40回

初期学習率は1e-4

Cosine Annealingで10回のパラメータ更新ごとに学習率を調整

パラメータの更新にはAdamを使用

損失関数による影響 (予測マスク)


損失関数を以下に設定して学習させる

- BCE損失
- soft-clDice損失 (α : 損失割合を表すパラメータ)

$$\mathcal{L}_{\text{clDice}} = (1 - \alpha)(1 - \text{Dice}) + \alpha(1 - \text{softclDice})$$

BCE損失, Dice損失では, 幅方向への拡張が小さい

soft-clDice損失において, α が大きくなると
幅方向への拡張が大きくなる



損失関数による影響 (評価指標)

- BCE損失, Dice損失では, 面積指標 (Dice) を大きく減少させずにネットワーク性 (clDice), 連続性 (VCA)を改善
- soft-clDice損失において, α を大きくしすぎると, 面積指標が大きく減少してしまい, 不適切だと判断

モデル	損失関数	Dice (↑)	clDice (↑)	VCA (↓)
U-Net (improved)	BCE損失	0.8217	0.8011	5.937×10
U-Net (improved) + increase	BCE損失	0.8208	0.8063	4.363×10
U-Net (improved) + increase	soft-clDice損失 ($\alpha=0.0$)	0.8202	0.8058	4.435×10
U-Net (improved) + increase	soft-clDice損失 ($\alpha=0.5$)	0.8124	0.8104	4.356×10
U-Net (improved) + increase	soft-clDice損失 ($\alpha=1.0$)	0.7714	0.8293	5.259×10

偏微分方程式を解く反復回数 N の影響 (評価指標)

N を10, 10^2 , 10^3 , 10^4 と増加させた場合の影響を確認

N が増えるにつれて、面積指標 (Dice) が減少してしまうが、
 $N = 10^3$ まではネットワーク性 (clDice) と連続性 (VCA) が改善

モデル	Dice (↑)	clDice (↑)	VCA (↓)
FR-UNet	0.8316	0.8103	3.664×10
FR-UNet + increase (N=10)	0.8307	0.8113	3.406×10
FR-UNet + increase (N= 10^2)	0.8278	0.8115	2.906×10
FR-UNet + increase (N= 10^3)	0.8165	0.8113	2.600×10
FR-UNet + increase (N= 10^4)	0.7739	0.8001	5.267×10

偏微分方程式を解く反復回数 N の影響 (予測マスク)

N が増加するにつれて,
断片部が徐々に接続される

N が大きくなりすぎると,
新たな断片部が発生してしまう
(VCAが悪化してしまう)



Ground truth



FR-UNet



FR-UNet +
increase ($N=10$)



FR-UNet +
increase ($N=10^2$)



FR-UNet +
increase ($N=10^3$)




FR-UNet +
increase ($N=10^4$)

付録：既存モデルによる方向推定への影響


36



U-Net



FR-UNet




予測マスク V_P , 真のマスク V_L で以下のように計算される

1. それぞれのスケルトン S_P, S_L を求める
2. $T_{prec} = \frac{|S_P * V_L|}{|S_P|}$, $T_{sens} = \frac{|S_L * V_P|}{|S_L|}$ を計算する
3. $clDice \leftarrow 2 \times \frac{T_{prec} \times T_{sens}}{T_{prec} + T_{sens}}$


付録：マスクのネットワーク構造

38

- 面積一致評価は高いが，ネットワーク構造が類似していない



- 面積一致評価は減少するが，ネットワーク構造が類似している



付録：二重閾値反復法[1]

39

[1] Liu+, JBHI, 2022

- クラス予測場 u から予測マスク V を生成するプロセス
 1. 低閾値 $\tau_L = 0.3$ と高閾値 $\tau_H = 0.5$ を設定
 2. 高閾値 τ_H を用いて初期予測マスク $V = \{i \mid u(i) > \tau_H\}$ を生成
 3. マスクが変化しなくなるまで、以下を反復
ピクセル i ($u(i) > \tau_L, i \notin V$)に対して、
その近傍ピクセルが V に含まれていれば、 i を V に含める
- 一般的な予測マスク V
 1. 閾値 $\tau = 0.5$ を設定
 2. 閾値 τ を用いてマスク $V = \{i \mid u(i) > \tau\}$ を生成


付録：二重閾値反復法[1]の高速化提案法

40

[1] Liu+, JBHI, 2022

• Max Poolingを用いた高速化を提案

1. 低閾値 $\tau_L = 0.3$ と高閾値 $\tau_H = 0.5$ を設定
2. 2種類のマスク $V = \{i \mid u(i) > \tau_H\}$ と $V_L = \{i \mid u(i) > \tau_L\}$ を生成
3. マスク V が変化しなくなるまで、以下を反復
 $V \leftarrow \text{maxpool}(V) * V_L$ で更新



• 成果

二重閾値反復法を高速化する手法を開発

- 元論文実装： 3.43×10^2 [秒/画像]
- 提案法： 6.13×10^{-2} [秒/画像]

モデル	後処理時間[秒/画像]	合計処理時間[秒/画像]
FR-UNet	-	0.0240
FR-UNet + DTI (paper)	343	343
FR-UNet + DTI (proposed)	0.0613	0.0853
FR-UNet + increase (N=10)	0.0801	0.104
FR-UNet + increase (N=10 ²)	0.237	0.261
FR-UNet + increase (N=10 ³)	2.08	2.10
FR-UNet + increase (N=10 ⁴)	19.9	19.9